Documento de Especificación de Requerimientos (SRS)

Sistema de Análisis Documental, OCR y Estadísticas (Actualización con PostgreSQL)

1. Introducción y Propósito del Sistema

El presente documento detalla los requerimientos técnicos y funcionales para el desarrollo de un sistema automatizado basado en Python. El objetivo principal es procesar documentos digitales y escaneados (archivos PDF) aplicando Reconocimiento Óptico de Caracteres (OCR). El sistema debe extraer la información, generar resúmenes estructurados de los relatos o hechos documentados, e identificar, clasificar y cuantificar entidades operativas críticas: **vehículos, armas y drogas**. Finalmente, la información consolidada debe ser exportada automáticamente a un documento Microsoft Word (.docx) ajustado a las plantillas y formatos preestablecidos, alimentando obligatoriamente una base de datos **PostgreSQL** para mantener un historial auditable y generar estadísticas operativas de alto valor.

2. Arquitectura Tecnológica Sugerida (Stack Informático)

> - **Backend y Lógica Central:** Python.
> - **Extracción y OCR:** `Tesseract OCR` y `PyMuPDF`.
> - **Procesamiento de Lenguaje Natural (NLP):** Integración de modelos de lenguaje o librerías como `spaCy`.
> - **Exportación a Plantillas Word:** `python-docx` y `docxtpl`.
> - **Historial y Estadísticas (Obligatorio):** Base de datos relacional **PostgreSQL** acoplada a `pandas` y herramientas de visualización para el análisis, cruce de información, almacenamiento de historial de documentos procesados y cálculo de métricas operacionales a lo largo del tiempo.

3. Requerimientos Funcionales

RF-01: Módulo de Carga y Preprocesamiento

- Interfaz gráfica de usuario que permita la carga masiva o individual de archivos PDF.

RF-02: Motor OCR y Extracción de Texto

- Reconocimiento y digitalización de texto incrustado en imágenes dentro de los PDF.

RF-03: Módulo de Resumen e Inteligencia Artificial

- Generación de una síntesis clara del relato, aislando la información sustancial.

RF-04: Extracción y Clasificación de Entidades

- **Vehículos:** Marcas, modelos, años de fabricación, colores y PPU.
- **Armas:** Fuego, fogueo, blancas, calibres, marcas, modelos y series.
- **Drogas:** Sustancias y aislamiento de medidas y pesos.

RF-05: Módulo de Exportación a Formato Word (.docx)

- Poblado dinámico de documentos Word pre-formateados editables.

RF-06: Persistencia e Historial en PostgreSQL

- Todo documento procesado debe generar un registro inmutable en la base de datos PostgreSQL, almacenando los metadatos del archivo, el texto original, el resumen generado y las entidades extraídas.
- Capacidad de consultar el historial completo de procesamientos mediante filtros por fecha, tipo de entidad (vehículo, arma, droga) o palabra clave en el relato.

RF-07: Tablero de Estadísticas y Control

- Conexión directa a PostgreSQL para la actualización automática de tablas y dashboards estadísticos tras cada procesamiento de documento.
- Elaboración de conteos acumulativos y reportes estadísticos históricos exportables.

4. Requerimientos No Funcionales

- **Seguridad e Integridad:** Ejecución preferentemente on-premise. La base de datos PostgreSQL debe contar con esquemas de respaldo (backups) automáticos y control de acceso.
- **Usabilidad y Escalabilidad:** El esquema de base de datos PostgreSQL debe diseñarse normalizado, permitiendo la escalabilidad para futuras entidades.

Hoja de Ruta del Proyecto: Sistema de Análisis Documental con OCR, IA y PostgreSQL

El presente documento establece la planificación estratégica y operativa para el desarrollo del sistema automatizado de procesamiento de actas y documentos. El proyecto abarca desde el 18 de agosto hasta el 23 de octubre, estructurado bajo un enfoque de ingeniería informática iterativa para garantizar la entrega continua de valor.

1. Metodología de Desarrollo

Se aplicará un marco de trabajo ágil adaptado a las necesidades institucionales:

- **Ciclos de Iteración (Sprints):** Periodos de una semana calendario (martes a lunes).
- **Interacción Semanal:** Las revisiones de avance se ejecutarán todos los martes por la mañana. En estas sesiones se validará el software en funcionamiento y se planificará el bloque técnico de la siguiente fase.
- **Enfoque Modular:** Cada iteración culminará con un módulo informático independiente, evaluable y funcional.

2. Cronograma de Iteraciones (18 de agosto – 23 de octubre)

Iteración	Fechas	Objetivos del Ciclo	Entregable para la Revisión Semanal
Sprint 1	18 Ago - 24 Ago	Configuración de arquitectura base e Interfaz de carga.	Interfaz web operativa donde se puede subir un archivo PDF y visualizarlo

Iteración	Fechas	Objetivos del Ciclo	Entregable para la Revisión Semanal
			correctamente.
Sprint 2	25 Ago - 31 Ago	Implementación del motor OCR y preprocesamiento de imágenes.	El sistema extrae el texto crudo de PDFs escaneados o digitales utilizando procesamiento de imágenes previo.
Sprint 3	01 Sep - 07 Sep	Integración de IA para generación de resúmenes (NLP).	Módulo que procesa el texto extraído y redacta una síntesis coherente de los hechos documentados.
Sprint 4	08 Sep - 14 Sep	Motor de Extracción de Entidades: Vehículos y Armas.	Sistema capaz de identificar y aislar marcas, modelos, patentes, calibres, y números de serie.
Sprint 5	15 Sep - 21 Sep	Motor de Extracción de Entidades: Drogas y afinamiento general.	Identificación de tipos de sustancias, pesajes y medidas. Se considera una carga de trabajo ajustada considerando los

Iteración	Fechas	Objetivos del Ciclo	Entregable para la Revisión Semanal
			feriados de Fiestas Patrias.
Sprint 6	22 Sep - 28 Sep	Módulo de inyección en plantillas de Word.	Generación y descarga de un archivo .docx que integra los datos extraídos en los campos específicos de la plantilla institucional.
Sprint 7	29 Sep - 05 Oct	Modelado de base de datos (PostgreSQL) e integración de persistencia histórica.	Conexión operativa a una base de datos PostgreSQL diseñada para el registro histórico inmutable de los documentos, textos, entidades y resúmenes procesados.
Sprint 8	06 Oct - 12 Oct	Desarrollo del Tablero de Control y Estadísticas Operativas.	Interfaz visual con gráficos y conteos (incautaciones acumuladas, estadísticas de vehículos, armas, drogas) consultando

Iteración	Fechas	Objetivos del Ciclo	Entregable para la Revisión Semanal
			directamente el historial de la base de datos PostgreSQL.
Sprint 9	13 Oct - 19 Oct	Pruebas de integración, manejo de excepciones y seguridad.	Sistema estabilizado frente a PDFs corruptos y validación de los mecanismos de respaldo de la base de datos PostgreSQL y protección de la información.
Sprint 10	20 Oct - 23 Oct	Despliegue on-premise, documentación técnica y marcha blanca.	Instalación final en el entorno de producción, entrega del código fuente y cierre del proyecto.

3. Gestión de Riesgos y Puntos Críticos

- **Calidad del Material Inicial (Sprint 2):** La eficacia del OCR depende directamente de la legibilidad de las actas escaneadas. Será prioritario incorporar filtros robustos para nivelar el contraste antes de extraer el texto.
- **Precisión de Reconocimiento de Entidades (Sprints 4 y 5):** El modelamiento de la extracción (NER) requiere iteraciones precisas para que la inteligencia artificial comprenda e identifique la terminología operativa y legal específica sin generar falsos positivos.

- **Integridad de las Plantillas Oficiales (Sprint 6):** Las inyecciones de datos variables (especialmente resúmenes extensos) pueden quebrar el diseño de un documento Word. Se deben aplicar reglas de anclaje para mantener inalterados los márgenes y logos institucionales.
- **Manejo del Historial y Concurrencia (Sprint 7 y 8):** Dado que PostgreSQL será el núcleo estadístico e histórico, se debe diseñar un esquema de base de datos sólido que soporte futuras consultas complejas y garantice la inmutabilidad de los registros históricos.